Experiment 5

Aim

Perform Morphological Analysis on a word.

Theory

Morphemes are considered as smallest meaningful units of language. These morphemes can either be a root word(play) or affix(-ed). Combination of these morphemes is called morphological process. So, word "played" is made out of 2 morphemes "play" and "-ed". Thus finding all parts of a word(morphemes) and thus describing properties of a word is called "Morphological Analysis". For example, "played" has information verb "play" and "past tense", so given word is past tense form of verb "play".

A morphological analyzer is a program that analyzes the morphology of an input word. It uses rules to identify the root and grammatical features of given words. It splits a given word into it's root, lexical category, gender, number, person, case, case marker or tense aspect modality(TAM), suffix and other required grammatical features as given below.

1. root : Root of the word (e.g. ladZake word has root ladZakA)
2. cat : Category of the word (e.g. Noun=n, Pronoun=pn, Adjective=adj, verb=v, adverb=adv post-position=psp and avvya=avy)
3. gen : Gender of the word
4. num : Number of the word (e.g. Singular=sg, Plural=pl, dual, and any)
5. per : Person of the word (e.g. 1st Person=1, 2nd Person=2, 3rd Person=3, and any)
6. case : Case of the word (e.g. direct=d, oblique=o and any)
7. tam : Case marker for noun or Tense Aspect Mood(TAM) for verb of the word
8. suff : Suffix of the word

Analysis of a word

बच्चों (bachchoM) = बच्चा (bachchaa) (root) + ओं (oM) (suffix)
(ओं=3 plural oblique)
A linguistic paradigm is the complete set of variants of a given lexeme. These variants can be classified according to shared inflectional categories (eg: number, case etc) and arranged into

tables.

Paradigm for बच्चा

case/num	singular	plural
direct	बच्चा(bachchaa)	बच्चे(bachche)
oblique	बच्चे(bachche)	बच्चों (bachchoM)

Algorithm to get बच्चों (bachchoM) from बच्चा (bachchaa)

1. Take Root बच्च (bachch) आ (aa)
2. Delete आ (aa)
3. output बच्च (bachch)
4. Add ओं (oM) to output
5. Return बच्चों (bachchoM)

Therefore, आ is deleted and ओं is added to get बच्चों

Add-Delete table for बच्चा

Delete	Add	Number	Case	Variants
आ(aa)	आ(aa)	sing	dr	बच्चा(bachchaa)
आ(aa)	ए(e)	plu	dr	बच्चे(bachche)
आ(aa)	ए(e)	sing	ob	बच्चे(bachche)
आ(aa)	ओं(oM)	plu	ob	बच्चों(bachchoM)

Paradigm Class

Words in the same paradigm class behave similarly, for Example लड़क is in the same paradigm class as बच्च, so लड़का would behave similarly as बच्चा as they share the same paradigm class.

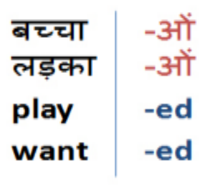

बच्चा	-ओं
लड़का	-ओं
play	-ed
want	-ed

Words can be analyzed morphologically if we know all variants of a given root word. We can use an 'Add-Delete' table for this analysis.

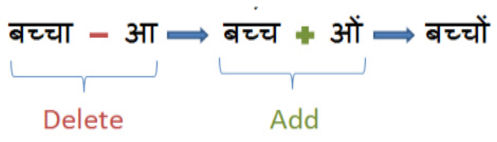

Code

```
import codecs
import re

# read the input file
filepath = "input.txt"
f = codecs.open(filepath, encoding="utf-8")
text = f.read()

sentences = text.split(u"।")  # since hindi sentences end with '।'
words_list = list()
for sentence in sentences:
    words = sentence.split(" ")  # words are seperated by a space in hindi
    words_list += words

suffixes = {
    1: [
        u"ाएगी",
        u"ाएगा",
        u"ाओगी",
        u"ाओगे",
        u"एंगी",
        u"ेंगी",
        u"एंगे",
        u"ेंगे",
        u"ूंगी",
        u"ूंगा",
        u"ातीं",
        u"नाओं",
        u"नाएं",
        u"ताओं",
        u"ताएं",
        u"ियाँ",
        u"ियों",
        u"ियां",
    ],
    2: [u"ो", u"े", u"ू", u"ु", u"ीय", u"ि", u"ा"],
    3: [u"कर", u"ाओ", u"िए", u"ाई", u"ाए", u"ने", u"नी", u"ना", u"ते", u"ीं", u"ती", u"ता",
u"ाँ", u"ां", u"ों", u"ें"],
    4: [
        u"ाकर",
        u"ाइए",
        u"ाईं",
        u"ाया",
        u"ेगी",
        u"ेगा",
        u"ोगी",
        u"ोगे",
        u"ाने",
        u"ाना",
        u"ाते",
        u"ाती",
        u"ाता",
        u"तीं",
        u"ाओं",
        u"ाएं",
        u"ुओं",
        u"ुएं",
        u"ुआं",
    ],
    5: [u"ाएंगी", u"ाएंगे", u"ाऊंगी", u"ाऊंगा", u"ाइयाँ", u"ाइयों", u"ाइयां"],
}

stems = list()
for word in words_list:
    for L in range(1, 5):
        if len(word) >= L + 1:
            for suffix in suffixes[L]:
                if word.endswith(suffix):
                    word = word[:-L]  # stripping the suffix from the word
                    try:
                        if word[-1] == u"ि":
                            word = word[:-1] + u"ी"
                    except:
                        print(word)
    if word:
        stems.append(word)

filename = "stems_generated.txt"
f = codecs.open(filename, "w", encoding="utf-8")  # open in write mode
for stem in stems:
    f.write(str(stem))
    f.write(u"\u0020")
f.close()
```

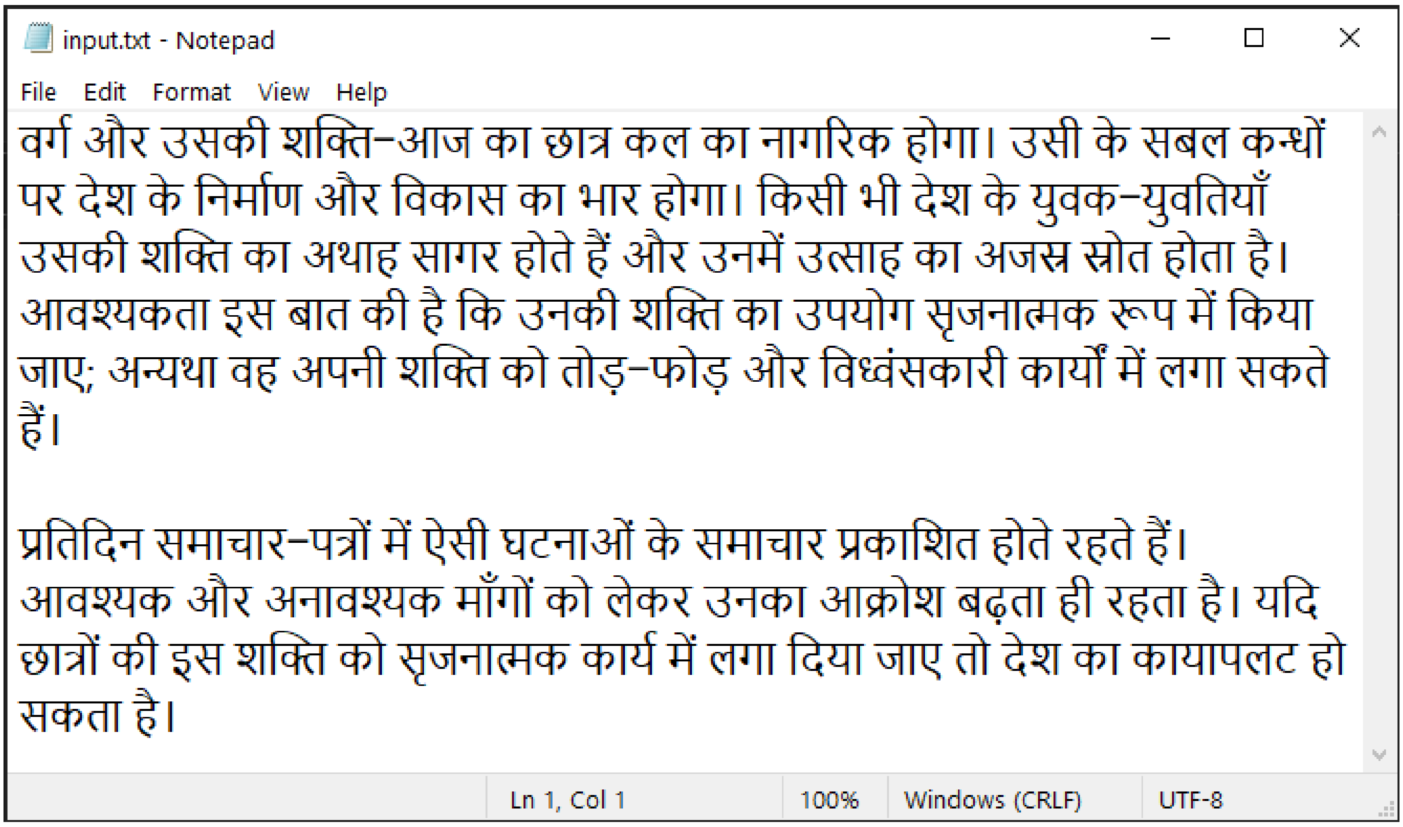

```
वर्ग और उसकी शक्ति–आज का छात्र कल का नागरिक होगा। उसी के सबल कन्धों
पर देश के निर्माण और विकास का भार होगा। किसी भी देश के युवक–युवतियाँ
उसकी शक्ति का अथाह सागर होते हैं और उनमें उत्साह का अजस्र स्रोत होता है।
आवश्यकता इस बात की है कि उनकी शक्ति का उपयोग सृजनात्मक रूप में किया
जाए; अन्यथा वह अपनी शक्ति को तोड़–फोड़ और विध्वंसकारी कार्यों में लगा सकते
हैं।

प्रतिदिन समाचार–पत्रों में ऐसी घटनाओं के समाचार प्रकाशित होते रहते हैं।
आवश्यक और अनावश्यक माँगों को लेकर उनका आक्रोश बढ़ता ही रहता है। यदि
छात्रों की इस शक्ति को सृजनात्मक कार्य में लगा दिया जाए तो देश का कायापलट हो
सकता है।
```

Output

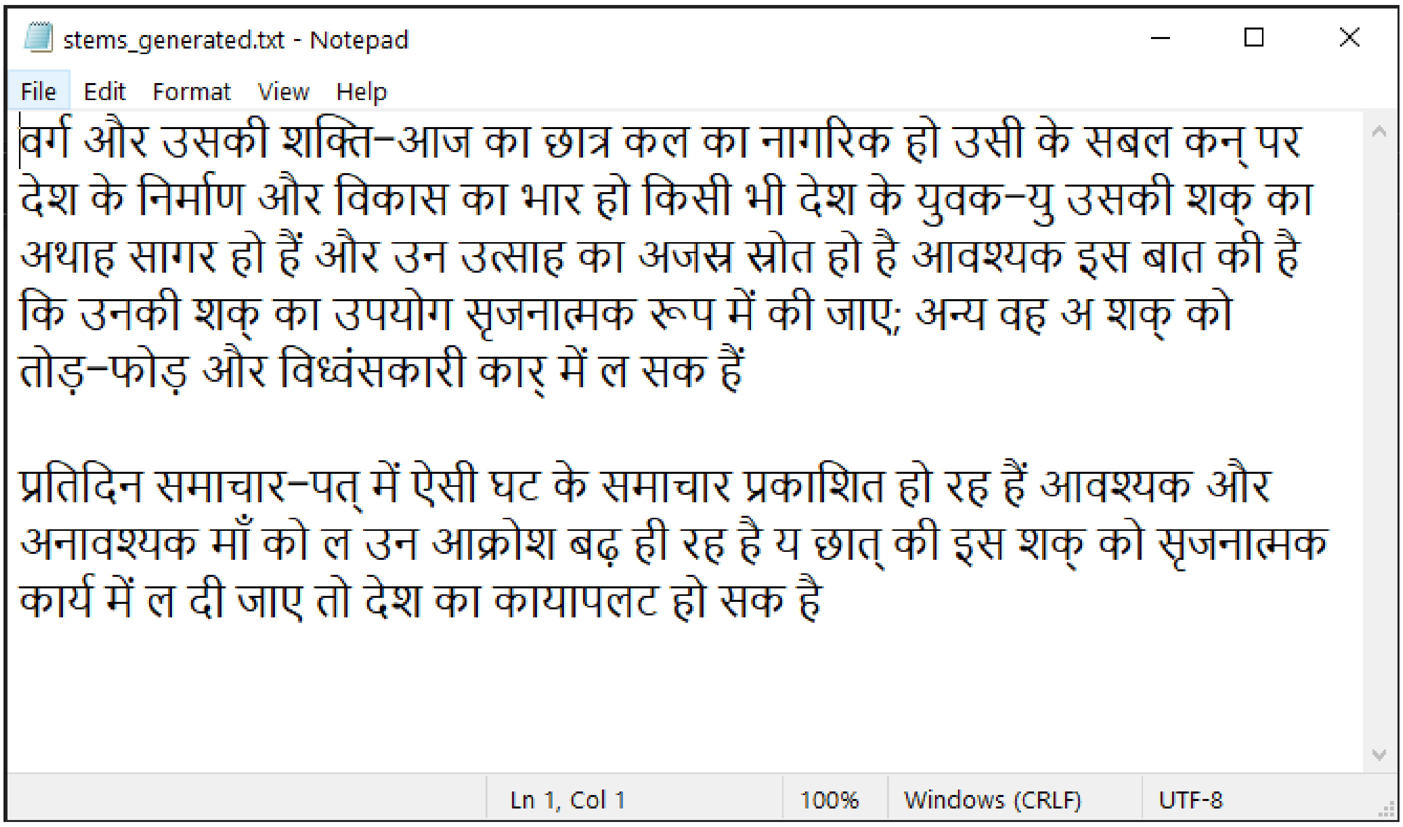

```
वर्ग और उसकी शक्ति–आज का छात्र कल का नागरिक हो उसी के सबल कन् पर
देश के निर्माण और विकास का भार हो किसी भी देश के युवक–यु उसकी शक् का
अथाह सागर हो हैं और उन उत्साह का अजस्र स्रोत हो है आवश्यक इस बात की है
कि उनकी शक् का उपयोग सृजनात्मक रूप में की जाए; अन्य वह अ शक् को
तोड़–फोड़ और विध्वंसकारी कार् में ल सक हैं

प्रतिदिन समाचार–पत् में ऐसी घट के समाचार प्रकाशित हो रह हैं आवश्यक और
अनावश्यक माँ को ल उन आक्रोश बढ़ ही रह है य छात् की इस शक् को सृजनात्मक
कार्य में ल दी जाए तो देश का कायापलट हो सक है
```

Conclusion

Hence, we have successfully performed morphological analysis on a Hindi text.